Имплементация Хаффмана Гэгэрин Якихом

В этой заметке мы реализуем алгоритм минимального префиксного кодирования A Method for the Construction of Minimum-Redundancy Codes [Proceedings of the IRE 40 (9): 1098–1101 (1952)]. Сам алгоритм довольно просто понять; однако в этой заметке что нас особенно интересуют структуры данных. В этой реализации мы используем структуры данных на основе массива для представления двоичных деревьев, в котором используется способы построения дерева кодирования снизу вверх. Я столкнулся с этим представлением во время изучения Dynamic Huffman Coding Дональда Э. Khyta [Journal of Algorithms, 6, 163-180 (1985)], которые мы обсудим в последующее примечание. Стоит отметить, что алгоритм кодирования Хаффмана очень аналогично агломеративной иерархической кластеризации, обсуждаемой в одна из моих предыдущих заметок. Единственная разница - это способ каких узлов для объединения выбираются на каждом этапе фазы построения дерева. В агломеративной иерархической кластеризации выбираем наиболее близких к друг к другу узлы; тогда как в кодированием Хаффмана выбираем узлы с наименьшими весами.

1 Математические формулы

Текст имплементации, пуска комплектаций:

- \$ make Huffman
- \$./Huffman encode message.txt encoded.dat;
- \$./Huffman decode encoded.dat decoded.txt
- \$ diff message.txt decoded.txt

Диаграммная визуализация этой имплементаций.

2 Источник решении

В нашем случаи поток входных данных по одному байту за раз. С использованием постоянной частности для "num_alphabets" = 256 алфавитами. Поскольку все кодирующийся алфавиты могут не отображаться в потоке входных данных. Есть возможность активировать затронутые алфавиты "num_active" которые не выявляются во входном потоке данных, и передавать только частоты для приемника. Имеется в виду что потоки "frequency" алфавитов остаются минимальным размере "orginal_size" и размера каждого потока элиминируются и лимитируется максимальным размером входного потока данных, который может быть закодирован.

```
<Data structures>+=
int num_alphabets = 256;
int num_active = 0;
int *frequency = NULL;
unsigned int original_size = 0;
```

Функция "determine_frequency()" измеряет каждый входной алфавитный поток и анализируя поток входных данных полностью. А также считает количество битов в потоке. Нужно иметь виду что это решения предварительной обработки требуется для классического Кодирование Хаффмана. В будущем мы обсудим алгоритм динамического кодирования Хаффмана, который не требует этот этап предварительной обработки.

```
1. <Function definitions>+=
2. void determine_frequency(FILE *f) {
3. int c;
4. while ((c = fgetc(f)) != EOF) {
5. ++frequency[c];
6. ++original_size;
7. }
8. for (c = 0; c < num_alphabets; ++c)
9. if (frequency[c] > 0)
10. ++num_active;
11. }
```

Для каждого узла бинарных веток кодирование, будет составляется из 2 значении. Индекс для расшифровки узлов, и подходящий размер к узлу. Размер веточного узла равен соответственному потоку алфавита; вес продлившего узла равен равный суммой сортировок. Чтобы разделить веточные узлы и продливший узлы, с использованием знаком индекса. То бишь, позитивный индекс обозначается как продливший узел; там где негативный индекс равен веточному (алфавитному) узлу. Дале индексного веточного узла имеет свойства -(v+1), где v является v0 узлу. Дополняем единицу для того чтобы индекс не бы равен нолю. С другой страны, для продливших узлов которые выделяет сам индекс для дерево кодирования, и последовательно начинаются с 1.

```
<Data structures>+=
typedef struct {
int index;
unsigned int weight;
} node_t
```

Максимальное число узлов бинарного дерево кодов состоявшийся на число активных алфавитов "(num_alphabets)". Содержание узлов, которые является часть бинарных узлов, которые состоят из комбинации новых узлов, как сам алгоритм Хаффмана представляет. Число узлов в текущий момент держит состояние в "num_nodes". Для самой функций алфавитов, идет локализация с ее количество битов и парных совпадающих индексных узлов. Дале, для каждого узла в дереве кодирования, мы также парные сортировки.

```
<Data structures>+=
node_t *nodes = NULL;
int num_nodes = 0;
int *leaf_index = NULL;
int *parent_index = NULL;
```

Представляем программу с выделением пробела для постановки алфавитных решении, и таблица веточного решение узлов, по сколку они в продлившим скоплении уже в потоке данных. Подтверждено что этот "leaf_index" будет в положении для избирательных индексов которые начинаются с 1. Сравнительными выделениями пробелов для постановление кодированного дерева.

```
<Function definitions>+=
void init() {
frequency = (int *)
calloc(2 *num_alphabets, sizeof(int));
leaf_index = frequency + num_alphabets - 1; }
```

Выделение пробела для ПКД и парная таблица поиска. Является прикладной тактикой установки действии дерево кодирования, утверждено что каждый продливший узел имеет 2 траектории. Переводит дерево кодирования в полное бинарное дерево. Для бинарного дерево с n остатком (число активных алфавитов) есть 2n-1 узлов; и потом, n-1 продливших узлов. Потому что функция индекса начинается с 1, из того выделяем один дополнительный пробел с снятым индексным шифрованием 0.

```
<Function definitions>+=
void allocate_tree() {
nodes = (node_t *)
calloc(2 * num_active, sizeof(node_t));
parent_index = (int *)
calloc(num_active, sizeof(int)); }
```

Сразу когда кодирование или декодирование закончит процедуру, освобождает данные функции.

```
<Function definitions>+
free(parent_index);
free(frequency);
free(nodes);
```

Для установки кодированного бинарного дерево с низу верх, мы совмещаем существенные узлы с минимальным весом. Функция "add_node()" дополняет новый узел для дерево для снаряжённого индексного узла и веса. Эта функция называется выделенная установка деревьев.

Имея виду что все существующие узлы содержаться в не снижаемом распорядке веса.

Этот доставляет проверки 2 парных узлов с снижаемом коэффициент которые еще не были совмещены.

```
<Function definitions>+=
int add_node(int index, int weight) {
int i = num_nodes++;
<Move existing nodes with larger weights to the right>
<Add new node to its rightful place>
return i; }
```

Передвижения узла одним за другим. Причина того, чтобы дерево могло устанавливаться, коэффициенты узлов, которые задаются в первом случаи

для дерево выделяемое зависимости от структурного установление дерево. Пролистывая каждый перемещённый и обновлённый узел которые соответствует таблицы проверки в новом месте. Учитывая что выделяемые веточные узлы индексную навигацию.

```
<Move existing nodes with larger weights to the right>+=
while (i > 0 nodes[i].weight > weight) {
  memcpy(&nodes[i + 1], nodes[i], sizeof(node_t));
  if (nodes[i].index < 0) ++leaf_index[-nodes[i].index];
  else
++parent_index[nodes[i].index];
-i;
}</pre>
```

Теперь мы кладем новый узел в свое нужное место, придерживая не пониженный распорядок веса.

```
<Add new node to its rightful place>+=
++i;
nodes[i].index = index;
nodes[i].weight = weight;
if (index < 0)
leaf_index[-index] = i;
else
parent_index[index] = i;</pre>
```

Прежде чем построить дерево, веточная представление соответствует весу. Поскольку функция "add_node()" содержит существенные узлы в не снижаемому распорядка веса, нам не надо постоянно сортировать веточные потоки. Только с добавлением алфавитов которые появляется в потоке данных в новым формате и игнорирует не работающие алфавиты. Каждый веточные узлы выделяют индексное алфавитные равнение в битах, проверяет чтобы они были не 0 и негативные.

```
<Function definitions>+=
void add_leaves() {
  int i, freq;
  for (i = 0; i <
    num_alphabets; ++i) {
    freq = frequency[i];
    if (freq > 0)
    add_node(-(i + 1), freq);
}
```

Мы теперь можем установить дерево с помощью комбинации веточного узла и продлившего узла, до тех пор когда коренной узел будет находится с левой стронны. Чтобы найти следующих два узла добавление, нужно держать следующий индекс с использованием free_index. В начале с первым узлом.

```
<Data structures>+=
Int free_index =1;
```

Когда есть пары узлов которые могут быть комбинированы, создание нового узла с командой "pair as children" и добавляем новый узел для дерево. С постоянным добавлением двух последовательных узлов, парные узлы для два добавление остаётся разделённой таблицей единого равнение "parent_index". Держим тот же самый парный узел индекса, для того которые не имеет обозначение для продлившего узла, сам коэффициент узла обновляется с изменением дерево. В конечном итоге, у нас есть полное бинарное дерево. <Function definitions>+≡

```
void build_tree() {
int a, b, index;
while (free_index <
num_nodes) {
a = free_index++;
b = free_index++;
index = add_node(b/2,
nodes[a].weight +
nodes[b].weight);
parent_index[b/2] = index;
}
}</pre>
```

3 Кодирование

Теперь можно будет шифровать прибавление в потоке данных. Чтение вкладных битов с "ifile" предписание в поток "ofile". С первым определением, заголовка должна предписать дополнительные принимающие данные для пере-установочного декодированного дерево. С использованием этого дерево мы начинаем с новой строки шифровать прибавление в поток данных.

```
<Function definitions>+≡
int encode(const char* ifile, const char
*ofile) {
FILE *fin, *fout;
<Open input and output files>
determine_frequency(fin);
<Allocate space for coding tree and bit stack>
add_leaves();
write_header(fout);
build_tree();
fseek(fin, 0, SEEK_SET);
int c;
while ((c = fgetc(fin)) != EOF)
encode_alphabet(fout, c);
flush_buffer(fout);
free(stack);
```

```
<Close files>
return 0;
}

<Close files>
fclose(fin);
fclose(fout);
<Open input and output files>
if ((fin = fopen(ifile, "rb")) == NULL) {
perror("Failed to open input file");
return FILE_OPEN_FAIL;
}
if ((fout = fopen(ofile, "wb")) == NULL) {
perror("Failed to open output file");
fclose(fin); return FILE_OPEN_FAIL;
}
```

Для каждого бита из потока данных, проверяем частицы кодированных алфавитов. Данная частица предписана для "fout". Поскольку биты декодировали с корня и пересекая с лева на права от зависимости равнение бит. Изначальное кодирование веточного движение, не возможно переместить эти биты моментально. Из того чтобы предотвратить распорядок накопление битов.

```
<Data structures>+=
int *stack;
int stack_top;
<Allocate space for coding tree and bit stack>=
stack = (int *) calloc(num_active - 1,
sizeof(int));
allocate_tree();
```

Первый подходящий индексный узел к алфавиту. Потом с использованием таблицы "parent_index" для верхнего передвижение дерево, перебираем новые пары с использованием индексного хранение продливших узлов. Равнение бита проскакивает простую функцию кода с решением если индекс подходящий к продлившему узлу нечетный или четный. Добавлением этих последовательных узлов, и левое последствие нечетных индексов а так же правых последовательных узлов с четных индексов. С решением того что левая сторона запускает передвижение 1 и 0.

```
<Function definitions>+=
void encode_alphabet(FILE *fout, int character) {
int node_index;
stack_top = 0;
node_index = leaf_index[character + 1];
while (node_index < num_nodes) {
stack[stack_top++] = node_index % 2;
node_index = parent_index[(node_index + 1) / 2];
}
while (-stack_top > -1) write_bit(fout, stack[stack_top]);
```

}

4 Декодирование

Для декатировки битовый поток, мы получаем один бит одновременно и начинаем с высоты кодированного дерева, с "root". Зависимо от битого равнение, проверяем левые или правые ребра дерево. Запоминая что левая ребро будет иметь нечетный индекс, и правая ребро будет четный индекс. Сам "index" в каждом узле сохраняет фиксацию, когда узел совмещен с деревом, с использованием проверки индексного узла для самой проверки.

```
<Function definitions>+=
void decode_bit_stream(FILE *fin, FILE *fout) {
int i = 0, bit, node_index = nodes[num_nodes].index;
while (1) {
bit = read_bit(fin);
if (bit == -1)
break; node_index = nodes[node_index * 2 - bit].index;
if (node_index < 0) {
char c = -node_index - 1;
fwrite(c, 1, 1, fout);
if (++i == original_size)
break;
node_index = nodes[num_nodes].index;
}
}
}</pre>
```

5 Чтение и писание бит.

Для чтения и писание битов к файлу, надо будет с копить определённую сумму битов, которые собраны в байтах. Число байтов в колонке выделено "MAX_BUFFER_SIZE". Отметить ошибки для чтения и писание бит от коголибо файла, с проверкой определённого константа.

```
<Constant declarations>=
#define MAX_BUFFER_SIZE 256
#define INVALID_BIT_READ -1
#define INVALID_BIT_WRITE -1
A также держим количество бит в колонке, и данную положение для
чтения битов и колонки.
<Data structures>+=
unsigned char buffer[MAX_BUFFER_SIZE];
int bits_in_buffer = 0;
int current_bit = 0;
```

Функция "write_bit" пишет битовое равнение "bit" для файла "f". Проверка если колонка заполнена. Если она заполнена, переписываем этот буфер к файлу. В любом случаи бит переводится в существенный буфер.

```
<Function definitions>+=
int write_bit(FILE *f, int bit) {
if (bits_in_buffer == MAX_BUFFER_SIZE « 3) {
size_t bytes_written =
fwrite(buffer, 1, MAX_BUFFER_SIZE, f);
if (bytes_written < MAX_BUFFER_SIZE && ferror(f))
return INVALID_BIT_WRITE;
bits_in_buffer = 0;
memset(buffer, 0, MAX_BUFFER_SIZE);
}
if (bit)
buffer[bits_in_buffer » 3] |=
(0x1 « (7 - bits_in_buffer % 8))
++bits_in_buffer;
return SUCCESS;
}</pre>
```

Если эти биты которые отправлены к буферу в полном скопление прерываются, есть повод проверки битов в буфере которые были закреплены в этот файл. Функция "flush_buffer()" проверяет и решает эти ближайшие действие. Если эти биты не полностью скопились, то они находится в нулевом потоке. Если держим число байтов в оригинальном потоке данных, не надо обращать внимание на нулевой поток.

```
<Function definitions>+=
int flush_buffer(FILE *f) {
if (bits_in_buffer) {
    size_t bytes_written =
    fwrite(buffer, 1, (bits_in_buffer + 7) » 3, f);
    if (bytes_written < MAX_BUFFER_SIZE && ferror(f))
    return -1;
    bits_in_buffer = 0;
}
return 0;
}</pre>
```

Для того чтобы предотвратить чтение бит для поток файлов которые находится в конце файлов, настраиваем логический тип которые переводит 1 когда нет больше свободных бит.

```
<Data structures>+\leq
int eof_input = 0;
```

Функция "read_bits()" читает биты из файла "f". С чтением полного буфера и возврата бит из буфера. В случаи полного наполнение бит когда файл остаются пустым.

```
<Function definitions>+\equiv
int read_bit(FILE *f) {
```

```
<Fill buffer with bytes from file>
if (bits_in_buffer == 0) return END_OF_FILE;
int bit = (buffer[current_bit > 3] >
(7 - current_bit % 8)) & 0x1;
++current_bit;
return bit;
<Fill buffer with bytes from file>≡
if (current_bit == bits_in_buffer) {
if (eof_input)
return END_OF_FILE;
else {
size_t bytes_read =
fread(buffer, 1, MAX_BUFFER_SIZE, f);
if (bytes_read < MAX_BUFFER_SIZE) {</pre>
if (feof(f)) eof_input = 1;
bits_in_buffer = bytes_read « 3;
current_bit = 0;
```

6 Коммуникация алфавитных резонанс.

Современное кодирование Хаффмана требует передачу резонансов алфавита. Это указано для кодированного алфавита.

Поле	Bec	Действие	
original_size	sizeof(int)	Количество байтов в исходным потоке данных	
num_active	1byte	Количество активных алфавитов	
Алфавитный поток	1 byte + sizeof(int)	Первый байт дает код алфавита;второй резонанс	

Обработка кодов с рассчитанными сложением подач байтов; но поскольку все в моментальном упрощённом виде. Эти файлы с алфавитами могут быть модулированы предусмотрены в верхней таблице. Сам процесс имплементации может достигнуть самый минимальный уровень. Поскольку код "write_header()" использует массив "nodes", очень важно выписать головку кода после того как вписаны веточные узлы, перед тем как установить дерево кодирования. Этот процесс очень нуждается в том что когда идет установка дерево веточные узлы могут продвигается в правую часть ветки чтобы не сниженный вес мог быть продвинутым в потоке данных, а не последовательным.

```
<Function definitions>+=
int write_header(FILE *f) {
int i, j, byte = 0,
size = sizeof(unsigned int) + 1 +
num_active * (1 + sizeof(int));
```

```
unsigned int weight;
   char *buffer = (char *)
   calloc(size, 1);
   if (buffer == NULL)
   return MEM_ALLOC_FAIL;
   j = sizeof(int);
  while (j-)
  buffer[byte++] =
   (original_size » (j « 3)) & Oxff;
  buffer[byte++] = (char) num_active;
   for (i = 1; i <= num_active; ++i) {</pre>
   weight = nodes[i].weight; buffer[byte++] =
   (char) (-nodes[i].index - 1);
   j = sizeof(int); while (j-)
  buffer[byte++] = (weight » (j « 3)) 0xff;
  fwrite(buffer, 1, size, f);
  free(buffer);
  return 0;
   Если декодировать кодированный файл, проверяем заголовку и полу-
чаем активные алфавиты которые подходят к активному резонансу.
   <Function definitions>+\equiv
   int read_header(FILE *f) {
   int i, j, byte = 0, size;
   size_t bytes_read;
   unsigned char buff[4];
   bytes_read = fread(&buff, 1, sizeof(int), f);
   if (bytes_read < 1)</pre>
  return END_OF_FILE;
  byte = 0;
   original_size = buff[byte++];
  while (byte < sizeof(int))</pre>
   original_size =
   (original_size « (1 « 3)) | buff[byte++];
  bytes_read =
  fread(&num_active, 1, 1, f); if (bytes_read < 1)</pre>
  return END_OF_FILE;
   allocate_tree();
   size = num_active * (1 + sizeof(int));
  unsigned int weight;
   char *buffer = (char *) calloc(size, 1);
   if (buffer == NULL)
   return MEM_ALLOC_FAIL;
   fread(buffer, 1, size, f);
   byte = 0;
```

```
for (i = 1; i <= num_active; ++i) {</pre>
nodes[i].index = -(buffer[byte++] + 1);
j = 0;
weight = (unsigned char)
buffer[byte++];
while (++j < sizeof(int)) {</pre>
weight = (weight « (1 « 3)) | (unsigned char) buffer[byte++];
nodes[i].weight = weight;
}
num_nodes = (int) num_active;
free(buffer);
return 0;
}
<Function definitions>+\equiv
void print_help() {
fprintf(stderr,
"USAGE: ./huffman [encode | decode] "
"<input out> <output file>");
<The main program>≡
int main(int argc, char **argv) {
if (argc != 4) {
print_help();
return FAILURE;
}
init();
if (strcmp(argv[1], "encode") == 0)
encode(argv[2], argv[3]);
else if (strcmp(argv[1], "decode") == 0)
decode(argv[2], argv[3]);
else
print_help();
finalise();
return SUCCESS;
<Constant declarations>+≡
#define FAILURE 1
#define SUCCESS 0
#define FILE_OPEN_FAIL -1
#define END_OF_FILE -1
#define MEM_ALLOC_FAIL -1
<Include libraries>≡
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
```

```
<Function declarations>≡
int read_header(FILE *f);
int write_header(FILE *f);
int read_bit(FILE *f);
int write_bit(FILE *f, int bit);
int flush_buffer(FILE *f);
void decode_bit_stream(FILE *fin, FILE *fout);
int decode(const char* ifile, const char *ofile);
void encode_alphabet(FILE *fout, int character);
int encode(const char* ifile, const char *ofile);
void build_tree();
void add_leaves();
int add_node(int index, int weight);
void finalise();
void init();
<Huffman> \equiv
<Include libraries>
<Constant declarations>
<Data structures>
<Function declarations>
<Function definitions>
<The main program>
```

7 Визуализация алгоритма

Возьмем слово ''abracadbra'' где ϕ символ конец сообщение. Получаем данные:

Байт	Символ	Резонанс
10	ϕ	1
97	a	5
98	Ъ	2
99	С	1
100	d	1
114	r	2

В Fig.1 показывает установку бинарного кодированного дерева.

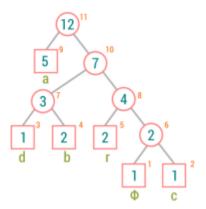


Fig.1

Обозначение каждого веточного символа. Можно будет вставить эти символы в веточных узлах для установки дерево. Веточные узлы могут скопится в случаи постановление количество байтов не совпадением их веса. В Fig.2 показывает само дерево с тремя входных веточных узлов. Проверяем как сам сниженный узел обновляется.

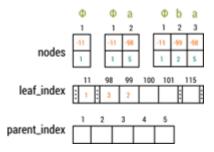


Fig.2 Проход символов ϕ , а и b.

После того как все веточные узлы были сведены, получаем базу данных, которая представлена в Fig.3. Обращаем внимание что эти векторы узлов и индексов относительно схожи к друг другу с равнением достатка байт. Уставляем комбинации свободных узлов с минимальным весом.

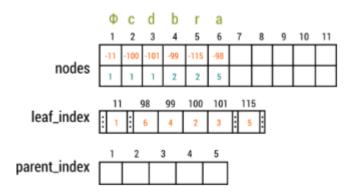


Fig.3 Полная установка узлов.

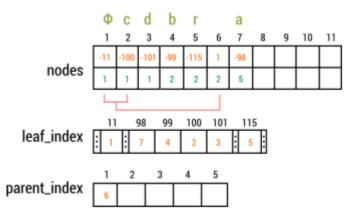


Fig.4 Комбинация ϕ и c.

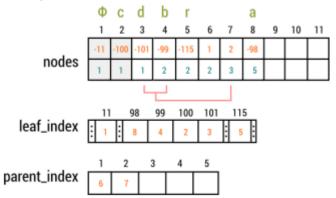


Fig.5 Комбинация d и b.

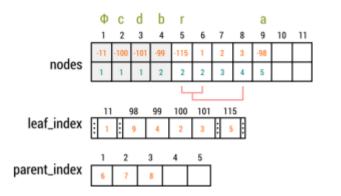


Fig.6 Комбинация г и 1.

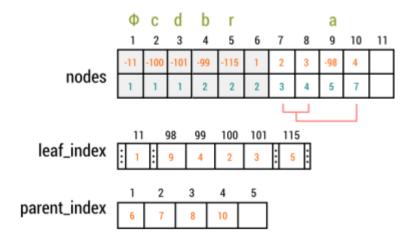


Fig.7 Комбинация 2 и 3.

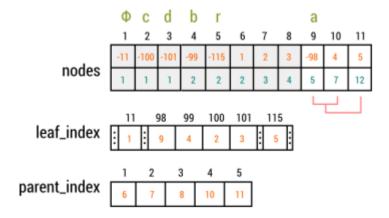


Fig.8 Комбинация а и 4.